TP3 - Pergunta de classificação de intenção

Pergunta: dado o texto de uma solicitação de atendimento ao cliente, qual é a intenção expressa pelo usuário? A entrada será apenas o texto da solicitação (`text`); a saída, uma das 46 intenções nominais publicadas no campo `intent` do Bitext Retail eCommerce. A categoria é uma taxonomia auxiliar, não um número ordinal. Resposta de referência, tags e nota de avaliação não entram como preditores do classificador.

Dados e distribuição das classes

O corpus preparado tem **44.884 solicitações em inglês**, distribuídas em **13 categorias e 46 intenções**. As classes têm de **721 a 1.000** exemplos (razão máximo/mínimo ≈ 1,39). A tabela apresenta a frequência de cada classe no corpus completo; a figura distribuição por intenção permite compará-las visualmente.

add_product (957)	open_account (987)	return_product_in_store (994)
availability (972)	order_history (988)	return_product_online (993)
availability_in_store (756)	pay (990)	sales_period (995)
availability_online (993)	payment_issue (996)	shipping_costs (974)
cancel_order (996)	payment_methods (995)	store_location (924)
change_account (987)	product_information (987)	store_opening_hours (992)
change_order (961)	product_issue (992)	submit_feedback (991)
close_account (995)	recover_password (993)	submit_product_feedback (994)
customer_service (992)	refund_policy (994)	submit_product_idea (995)
damaged_delivery (992)	refund_status (999)	technical_issue (994)
delivery_issue (996)	remove_product (993)	track_delivery (996)
delivery_time (920)	request_invoice (1.000)	track_order (988)
exchange_product (988)	request_refund (957)	use_app (999)
exchange_product_in_store (991)	request_right_to_rectification (989)	wrong_item (996)
human_agent (994)	return_policy (994)	missing_item (721)
return_product (994)		

Por que aprendizado supervisionado

O Bitext oferece exemplos de texto com intenção já rotulada pela fonte. Portanto, a tarefa é **classificação multiclasse supervisionada**: aprender associações linguísticas a partir do treino e prever um rótulo válido para novas solicitações. Codificar intenções como 0, 1, 2 etc. para usar regressão linear introduziria distâncias e ordem inexistentes entre classes; as saídas contínuas não seriam probabilidades nem rótulos válidos. R^2 e RMSE não medem o erro de intenção. Para essa pergunta, usaremos métricas de classificação, sobretudo Macro-F1, precisão, recall, suporte por intenção e matriz de confusão.

A regressão linear do notebook TP3 tem outro alvo, numérico: comprimento da resposta de referência. Ela serve como diagnóstico estatístico, **não** como classificador. O baseline TF-IDF + regressão logística já existente é apenas evidência interna no Bitext; seu Macro-F1 não pode ser extrapolado para português real.

Limite da validação externa

O B2W-Reviews01 contém avaliações reais em português, mas **nota não é intenção**. Uma amostra de 500 textos recebeu rótulos humanos e cobre **20 das 46 intenções**. Destes, 422 registros sem marca de incerteza são elegíveis para avaliação externa, cobrem **14 intenções** e permanecem fora do treinamento. O rótulo `submit_product_feedback` concentra 292 dos 422 elegíveis. A amostra foi estratificada por nota. A avaliação externa apresenta suporte por intenção e não atribui desempenho às 32 classes ausentes nem à distribuição natural de chamados. Veja o resultado PT-BR.

Fontes: Bitext Retail eCommerce, B2W-Reviews01 e relatório de validação PT-BR do projeto.